Proyecto Bioestadística: APOE4 y diagnóstico cognitivo en ADNI

Oct 16, 2026

1. Pregunta estadística

¿En adultos mayores del estudio ADNI, cada alelo APOE ε4 adicional (0, 1 o 2 copias) se asocia con un mayor puntaje basal en la escala CDR suma de cajas (CDR-SB), ajustando por edad, sexo, años de educación y raza?

El desenlace ya no es la etiqueta CN/MCI/demencia, sino el puntaje con el que ADNI la asigna (sección 2.1). El CDR-SB va de 0 (sin deterioro) a 18 (deterioro máximo) en pasos de 0.5.

Componente	Definición	Variable en ADNI
Población	Participantes enrolados en ADNI1, ADNI-GO, ADNI2, ADNI3 y ADNI4, de 50 a 91 años	`ADSL`, `ENRLFL = "Y"`
Exposición	Número de alelos APOE ε4 (0, 1, 2)	`APOE` (genotipo)
Comparador	0 alelos ε4 (ε2/ε2, ε2/ε3, ε3/ε3)	categoría de referencia
Desenlace principal (cuantitativo)	CDR suma de cajas basal, 0 a 18	`CDRSB`
Desenlace secundario	MMSE basal, 0 a 30 (menor = peor)	`MMSCORE`
Desenlace complementario (ordinal)	Diagnóstico basal: CN, MCI, demencia	`DX`
Covariables de ajuste	Edad, sexo, educación (años), raza	`AGE`, `SEX`, `EDUC`, `RACE`
Mediador (exploratorio)	Volumen hipocampal total ajustado por volumen intracraneal	`ADSP_PHC_T1_FS`

Hipótesis

- H0: la diferencia ajustada de medias de CDR-SB entre portadores y no portadores de ε4 es 0 ($\beta = 0$).
- H1: $\beta \neq 0$. Esperamos $\beta > 0$ y un gradiente dosis-respuesta (2 copias > 1 copia).

Diseño: estudio transversal analítico con datos secundarios de la visita basal de una cohorte multicéntrica. Modelo principal: regresión lineal múltiple con errores estándar robustos (tema 6.3.2 del sílabo). Sensibilidad: regresión binomial negativa (tema 6.5.1). Complementario: regresión logística ordinal sobre el diagnóstico (tema 6.5.2). $\alpha = 0.05$.

Por qué APOE4 y no el hipocampo como exposición: el genotipo se fija al nacer, así que siempre antecede al deterioro. La atrofia del hipocampo es parte del propio proceso neurodegenerativo, y en un

corte transversal no sabemos si vino antes o después. Por eso el hipocampo va como mediador en el DAG y no en el modelo de efecto total.

Por qué un desenlace cuantitativo: la etiqueta CN/MCI/demencia resume el CDR en tres cajas y pierde información: dos personas con MCI pueden tener CDR-SB de 0.5 y de 4.0. Con el puntaje, el modelo usa toda la variación y la interpretación es directa: cuántos puntos de CDR-SB más tiene, en promedio, un portador de ε4.

2. Base de datos pública: ADNI (paquete ADNIMERGE2)

Usamos los datos basales de la Alzheimer's Disease Neuroimaging Initiative (ADNI), una cohorte observacional multicéntrica iniciada en octubre de 2004. La financian el National Institute on Aging de EE. UU., empresas farmacéuticas y fundaciones, y recluta en más de 60 centros de EE. UU. y Canadá. Su objetivo es validar biomarcadores (resonancia, PET, LCR, genética) para detectar y seguir la enfermedad de Alzheimer.

Fuente y acceso. Los datos son públicos sin embargo para investigadores, previa firma del Data Use Agreement en el portal IDA de LONI (ida.loni.usc.edu). Descargamos el paquete R **ADNIMERGE2** (USC ATRI; Donohue y Hussen, versión de enero 2026), que trae 235 tablas e incorpora la fase ADNI4. Ya no incluye la tabla única `adnimerge`: hay que unir tablas.

Tablas que usamos

Tabla	Contenido	Variables usadas
`ADSL`	Una fila por participante, datos basales derivados	`SUBJID` (= RID), `ENRLFL`, `AGE`, `SEX`, `EDUC`, `RACE`, `DX`, `APOE`
`ADSP_PHC_T1_FS`	Resonancia T1 procesada con FreeSurfer y armonizada entre escáneres (ComBat)	`RID`, `PHC_SCANDATE`, `Left/Right_Hippocampus_combat`, `EstimatedTotalIntraCranialVol_combat`
`DXSUM`	Resumen diagnóstico por visita	`DXDDUE` (etiología de la demencia), solo para describir

El diccionario general es `DATADIC_15Oct2026.csv`; las variables de `ADSL` están definidas en la tabla `DERIVED_DATADIC` del paquete.

Flujo de selección de la muestra

1. Registros en `ADSL`: 5,138.
2. Enrolados (`ENRLFL = "Y"`): 3,041 (ADNI1 a ADNI4).
3. Con diagnóstico basal, genotipo APOE, edad, sexo, educación y raza completos: **2,861** (análisis principal).
4. Con resonancia a ±180 días del enrolamiento: **2,579** (análisis de mediación).

Descripción de la muestra analítica (n = 2,861)

Característica	Valor
Diagnóstico basal	CN 1,132 (39.6%) · MCI 1,272 (44.5%) · Demencia 457 (16.0%)
APOE ε4	0 copias 1,566 (54.7%) · 1 copia 1,027 (35.9%) · 2 copias 268 (9.4%)
Edad, mediana (RIC)	72.5 años (67.2 a 77.7); rango 50.5 a 91.4
Sexo femenino	1,417 (49.5%)
Educación, mediana (RIC)	16 años (14 a 18)
Raza	Blanca 2,381 (83.2%) · Negra 297 (10.4%) · Otra 183 (6.4%)
Fase de origen	ADNI1 818 · ADNI-GO 128 · ADNI2 779 · ADNI3 677 · ADNI4 459

Limpieza y cuidados

- `ADSL` guarda el RID en `SUBJID` (texto); las demás tablas usan `RID`. Hay que convertirlo antes de unir.
- APOE ε4 se codifica contando los "4" del genotipo (ε2/ε4 cuenta como 1 copia).
- Raza se agrupa en Blanca, Negra y Otra porque varias categorías tienen menos de 15 personas.
- Volumen hipocampal = izquierdo + derecho, ajustado por volumen intracraneal con el método de residuales (pendiente estimada en CN).
- "DEM" es demencia en general; en `DXSUM` el 98.7% de las demencias basales (625 de 633) figuran como debidas a Alzheimer.
- CDR-SB y MMSE definen el diagnóstico, así que ahora son desenlaces (principal y secundario) y nunca predictores. ADAS-Cog queda solo en la tabla descriptiva. Un participante no tiene CDR-SB: n = 2,860 para el desenlace principal.
- Hay IMC imposibles (2.5 y 235 kg/m²); no usamos IMC en el modelo.
- Es una muestra de conveniencia de voluntarios, muy educados y mayormente blancos: limita la generalización, por ejemplo a población peruana.

2.1 Cómo clasifica ADNI: el sistema de puntajes

ADNI no clasifica con una sola prueba: combina tres escalas con puntos de corte. La que manda es el **CDR global**; MMSE y memoria lógica separan MCI de demencia y confirman el déficit de memoria.

Criterio de ingreso	Cognitivamente normal	MCI	Demencia (Alzheimer)
CDR global	0	0.5 (caja de memoria ≥ 0.5)	0.5 o 1
MMSE	24 a 30	24 a 30	20 a 26

Criterio de ingreso	Cognitivamente normal	MCI	Demencia (Alzheimer)
Memoria lógica II diferida, ≥ 16 años de educación	≥ 9	≤ 8	≤ 8
Memoria lógica II diferida, 8 a 15 años	≥ 5	≤ 4	≤ 4
Memoria lógica II diferida, 0 a 7 años	≥ 3	≤ 2	≤ 2
Queja de memoria	No	Sí	Sí
Actividades diarias	Conservadas	Conservadas	Afectadas (criterios NINCDS-ADRDA)

Los cortes son los de ADNI1 y ADNI2 según resúmenes secundarios (tabla PMC5500648). ADNI-GO y ADNI2 usaron rangos más altos de memoria lógica para el MCI temprano, y ADNI3 cambió los cortes. Falta confirmarlos en los manuales de procedimientos de cada fase (ADNI, información de cohortes).

Verificación con nuestros datos (n = 2,860)

Regla	Coincidencia con DX
CDR global = 0 en los CN	1,123 de 1,131 (99.3%)
CDR global = 0.5 en los MCI	1,246 de 1,272 (98.0%)
CDR global ≥ 0.5 en las demencias	457 de 457 (100%); 222 con 0.5 y 235 con 1 o 2
Regla CDR global + MMSE (0 = CN; 0.5 con MMSE ≥ 24 = MCI; resto = demencia)	2,693 de 2,860 (94.2%)
Estadios de CDR-SB (0 = CN; 0.5 a 4.0 = MCI; ≥ 4.5 = demencia)	2,523 de 2,860 (88.2%)
Memoria lógica bajo el corte	CN 2.5% · MCI 61.5% · demencia 97.6%

En ADNI1 se ve el corte exacto: con ≥ 16 años de educación, todos los CN tienen memoria lógica ≥ 9 y todos los MCI ≤ 8. En ADNI3 y ADNI4 los rangos se superponen.

Por qué elegimos el CDR-SB como desenlace. El CDR puntúa seis áreas (memoria, orientación, juicio, vida comunitaria, hogar, cuidado personal) de 0 a 3. El CDR global, que define el diagnóstico, sale de esas mismas seis cajas; el CDR-SB las suma. Es la versión continua de la misma escala, sus estadios están validados (O'Bryant et al., *Arch Neurol* 2008) y es el desenlace principal de los ensayos clínicos de Alzheimer.

Candidato	A favor	En contra
CDR-SB (elegido)	Es la escala que define el diagnóstico; reproduce DX en 88%; 1 dato faltante	37% de ceros y sesgo a la derecha: hay que usar errores robustos o un modelo de conteo
MMSE (secundario)	Conocido, 2 faltantes	Efecto techo (mediana 29 en CN); mide cognición global, no estadio
Memoria lógica II	Criterio de ingreso	Sus cortes cambian por fase y educación
mPACC	Distribución más normal	No se usa para clasificar

3. Antecedentes

APOE ε4 es el principal factor de riesgo genético del Alzheimer de inicio tardío y su efecto crece con el número de copias. Lo nuevo de nuestro análisis es tratar CN, MCI y demencia como un desenlace ordinal único, en vez de comparar pares de grupos.

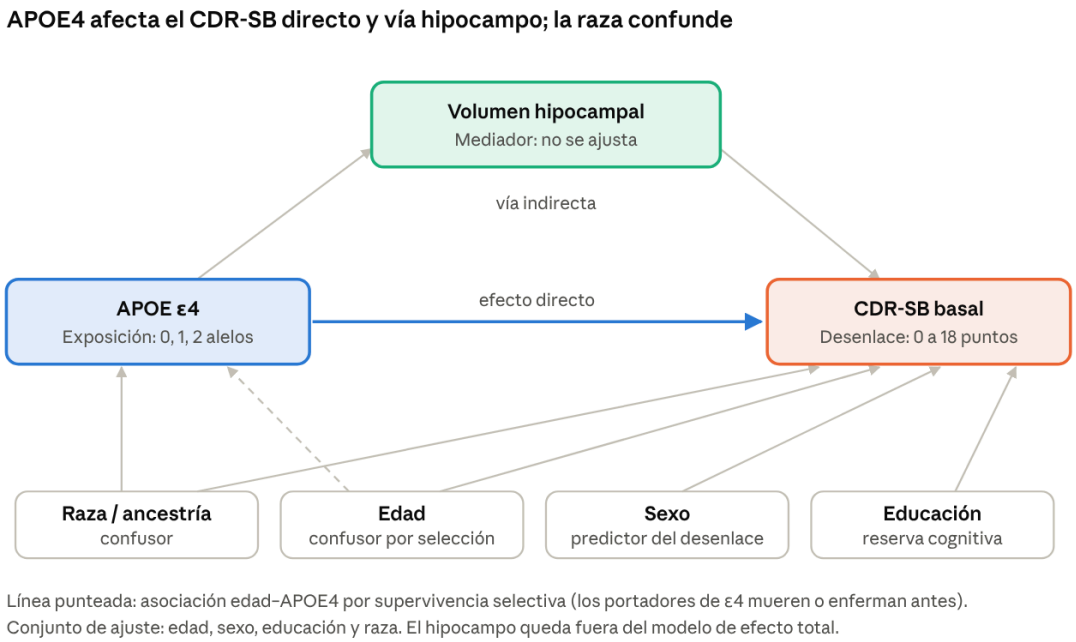
Estudio	Población	Hallazgo clave	Relevancia para nosotros
Corder et al., *Science* 1993	42 familias con Alzheimer tardío	El riesgo de Alzheimer sube de 20% a 90% y la edad de inicio baja de 84 a 68 años según el número de alelos ε4	Base del efecto dosis-respuesta: justifica codificar 0, 1, 2 copias
Farrer et al., *JAMA* 1997	Metanálisis de 40 equipos: 5,930 casos y 8,607 controles	En caucásicos, OR 3.2 para ε3/ε4 y 14.9 para ε4/ε4 frente a ε3/ε3; asociación más débil en afroamericanos e hispanos y variación por edad y sexo	Justifica ajustar por edad, sexo y raza
Hostage et al., *PLoS ONE* 2013	662 participantes de ADNI (CN, MCI, Alzheimer)	Efecto dosis-dependiente de ε4 sobre el volumen hipocampal en MCI y Alzheimer	Apoya el camino APOE4 → hipocampo del DAG
Identificación del volumen hipocampal como mediador (preprint medRxiv 2020)	Estudio Tres Ciudades, Dijon, 12 años de seguimiento	El hipocampo media solo una parte pequeña (6.7%) del efecto de APOE4 sobre demencia	El efecto de APOE4 no pasa todo por el hipocampo: mediación parcial

Estudio	Población	Hallazgo clave	Relevancia para nosotros
Estudio Rotterdam (mediación por neuroimagen)	5,510 adultos de población general	Poca evidencia de mediación por el hipocampo (ε4: 3%) para demencia incidente	Contraste: en población general el efecto mediado es menor que en cohortes clínicas

Vacío que llenamos: no encontramos estudios en ADNI que usen regresión logística ordinal con CN < MCI < demencia como desenlace y que cuantifiquen cuánto cambia el OR de APOE4 al añadir el hipocampo.

4. Diagrama acíclico dirigido (DAG)

La exposición es APOE ε4, el desenlace es el CDR-SB basal (el puntaje que define el diagnóstico) y el hipocampo es mediador. Ajustamos por edad, sexo, educación y raza, pero no por el hipocampo.



DAG · exposición, desenlace, mediador y 4 covariables

Variable	Rol	Por qué
APOE ε4	Exposición	Se fija en la concepción, así que siempre antecede al diagnóstico
CDR-SB basal	Desenlace	Cuantitativo, 0 a 18; el diagnóstico CN/MCI/demencia es su versión en categorías

Variable	Rol	Por qué
Volumen hipocampal	Mediador	APOE4 acelera la atrofia y la atrofia empeora la cognición. Ajustarlo quitaría parte del efecto que queremos medir
Raza / ancestría	Confusor	La frecuencia de ε4 cambia según ancestría y el riesgo de demencia también (Farrer 1997)
Edad	Confusor por selección	APOE4 no causa la edad, pero entre adultos mayores los portadores sobreviven menos, así que en la muestra se asocian. Además, es el mayor predictor del diagnóstico
Sexo	Predictor del desenlace	No causa el genotipo, pero cambia el riesgo y la fuerza del efecto de ε4. Se ajusta por precisión y se puede explorar como modificador
Educación	Predictor del desenlace	Reserva cognitiva: retrasa el diagnóstico. Tampoco causa el genotipo; se ajusta por precisión

Ojo con la idea del grupo: en sentido estricto, solo la raza es un confusor clásico (causa común de exposición y desenlace). Edad, sexo y educación no pueden causar un gen. Igual conviene ajustarlas: la edad por supervivencia selectiva, y sexo y educación porque predicen fuerte el desenlace y en un modelo logístico eso mejora la estimación. Vale la pena explicarlo así en la exposición, porque el profesor puede preguntar "¿cómo la educación va a causar APOE4?".

5. Plan de análisis

El modelo principal es una regresión lineal múltiple del CDR-SB con errores estándar robustos (HC3). En la corrida preliminar, 1 copia de ε4 suma 0.64 puntos y 2 copias suman 1.23 puntos de CDR-SB, ajustando por edad, sexo, educación y raza.

```
\text{CDR-SB}_i = \beta_0 + \beta_1\,\varepsilon4_{1,i} + \beta_2\,\varepsilon4_{2,i}
+ \beta_3\,\text{edad}_i + \beta_4\,\text{sexo}_i + \beta_5\,\text{educ}_i +
\beta_6\,\text{raza}_i + e_i
```

1. **Descriptivo (Tabla 1):** características por grupo de APOE4. Numéricas con mediana (RIC), porque CDR-SB y MMSE no son normales; categóricas con n (%).
2. **Bivariado:** CDR-SB por APOE4 con Kruskal-Wallis y correlación de Spearman (tendencia): $H(2) = 194.0$, $p < 0.001$; $rho = 0.26$, $p < 0.001$.
3. **Modelo crudo:** `lm(CDRSB ~ apoe4)`.
4. **Modelo ajustado (efecto total):** `lm(CDRSB ~ apoe4 + edad + sexo + educ + raza)` con errores robustos (`sandwich::vcovHC`, tipo HC3). No se ajusta por el hipocampo, porque es mediador.
5. **Post-regresión:** residuales (QQ-plot, Shapiro-Wilk), homocedasticidad (Breusch-Pagan), VIF, observaciones influyentes (distancia de Cook) y R^2 ajustado.

6. **Sensibilidad:** binomial negativa sobre 2 × CDR-SB (conteo de medios puntos, 0 a 36), que da razones de medias; MMSE como desenlace secundario; y el modelo ordinal sobre el diagnóstico.
7. **Exploratorio:** mediación por el hipocampo (cambio en β al añadirlo) e interacción APOE4 × sexo.

Resultados preliminares (diferencia de medias de CDR-SB frente a 0 copias, IC95% robusto)

Modelo	1 copia ε4	2 copias ε4
Lineal crudo (n = 2,860)	+0.66 (0.52 a 0.79)	+1.19 (0.94 a 1.43)
Lineal ajustado (n = 2,860)	+0.64 (0.50 a 0.77)	+1.23 (1.00 a 1.47)
Lineal ajustado, submuestra con resonancia (n = 2,579)	+0.63 (0.50 a 0.77)	+1.23 (0.98 a 1.48)
Lineal ajustado + volumen hipocampal (n = 2,579)	+0.37 (0.25 a 0.48)	+0.64 (0.42 a 0.87)
Binomial negativa ajustada, razón de medias (n = 2,860)	1.65 (1.49 a 1.83)	2.36 (2.01 a 2.78)
MMSE ajustado, diferencia en puntos (n = 2,858)	−0.92 (−1.12 a −0.72)	−1.88 (−2.23 a −1.52)
Ordinal sobre diagnóstico, OR (n = 2,861)	2.23 (1.91 a 2.60)	5.19 (4.02 a 6.72)

Los cuatro enfoques coinciden: hay un gradiente dosis-respuesta. Al añadir el hipocampo, el efecto de 2 copias baja de 1.23 a 0.64 puntos (cerca de la mitad), y cada cm^3 más de hipocampo se asocia con 0.83 puntos menos de CDR-SB. Es una mediación parcial. La interacción APOE4 × sexo no fue significativa ($F = 0.22$, $p = 0.81$).

Supuestos. Los residuales del modelo lineal no son normales (Shapiro-Wilk $p < 0.001$) y la varianza no es constante (Breusch-Pagan = 79.0, $p < 0.001$), algo esperable con 37% de ceros. Con n = 2,860 los coeficientes siguen siendo válidos para medias, pero los errores estándar deben ser robustos. Por eso la binomial negativa va como confirmación: modela un desenlace no negativo y con sobredispersión (theta = 0.77).

Tamaño de muestra. Con 7 coeficientes y 2,860 personas hay unas 400 observaciones por parámetro, muy por encima de la regla de 10 a 20.

6. Figuras

Hay tres figuras sin boxplots, y en todas cada punto es un participante. La Figura 1 responde la pregunta principal (CDR-SB); la Figura 2 muestra el mismo efecto sobre el diagnóstico y la Figura 3 el camino por el mediador.

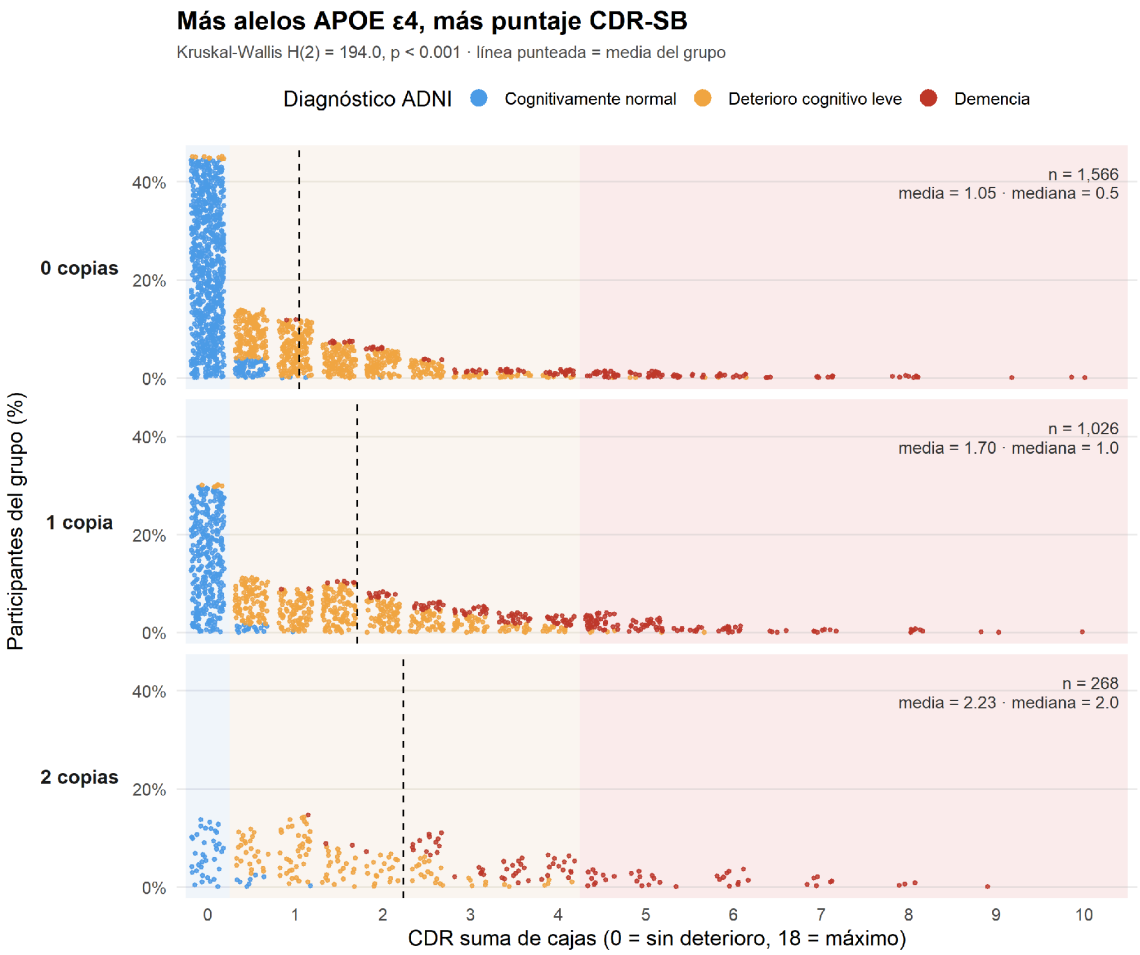


Figura 1. Distribución del puntaje CDR suma de cajas (CDR-SB) según el número de alelos APOE ε4 en 2,860 participantes de ADNI. Cada punto es un participante, ubicado en su puntaje; la altura de cada columna es el porcentaje de su grupo con ese puntaje. El color es su diagnóstico ADNI y las bandas de fondo marcan los estadios del CDR-SB (0 = normal; 0.5 a 4.0 = deterioro leve; ≥ 4.5 = demencia), así se ve cómo el puntaje define la clasificación. La línea punteada es la media del grupo: 1.05 (0 copias), 1.70 (1 copia) y 2.23 (2 copias). Se usó Kruskal-Wallis porque se comparan tres grupos independientes y el CDR-SB no es normal (37% de ceros, sesgo a la derecha): $H(2) = 194.0$, $p < 0.001$.

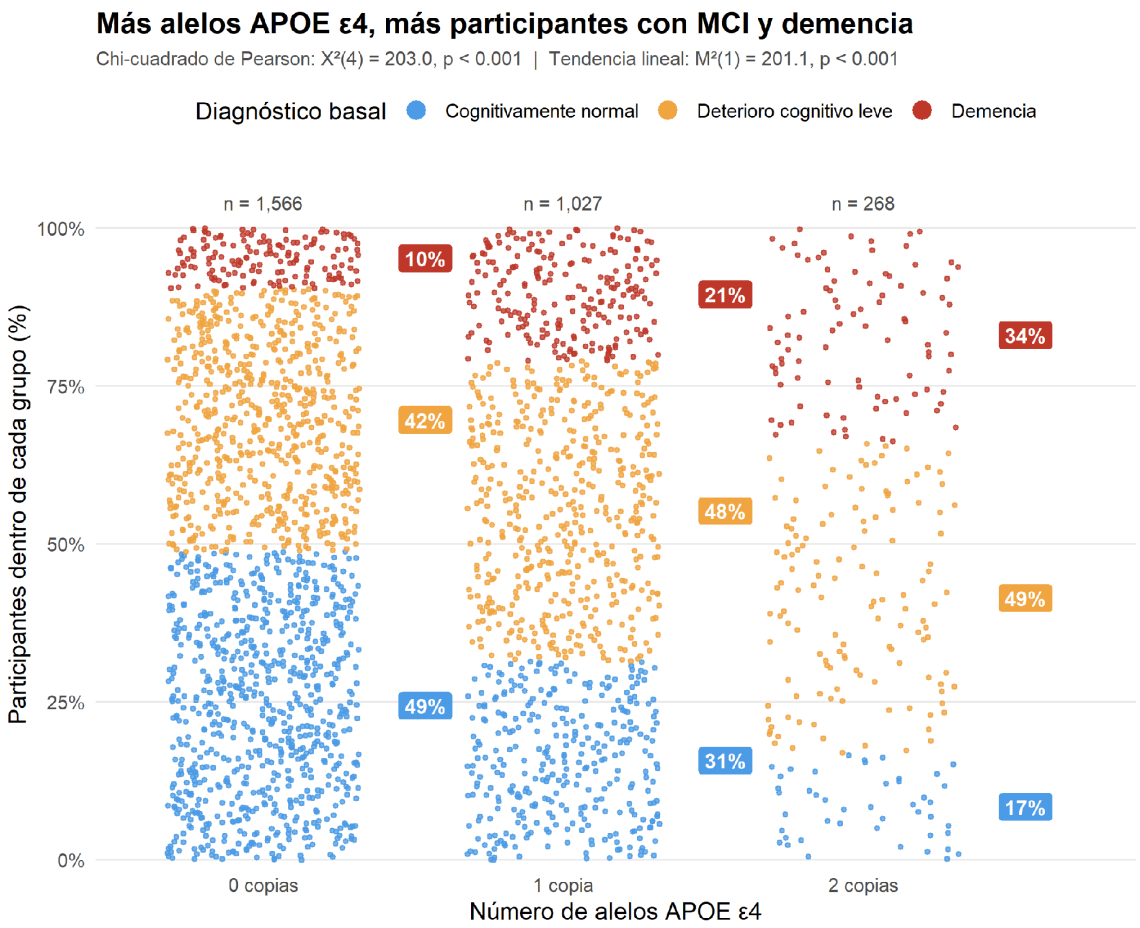


Figura 2. Distribución del diagnóstico cognitivo basal según el número de alelos APOE ε4 en 2,861 participantes de ADNI. Cada punto es un participante, apilado dentro de su grupo en orden CN, MCI y demencia; la altura de cada color es la proporción del grupo. La demencia sube de 10% (0 copias) a 21% (1 copia) y 34% (2 copias), y CN baja de 49% a 17%. Se usó la prueba chi-cuadrado de Pearson de independencia porque ambas variables son categóricas y todas las frecuencias esperadas fueron ≥ 5 (mínima 42.8): $\chi^2(4) = 203.0$, $p < 0.001$. Como ambas son ordinales, se añadió la prueba de tendencia lineal de Mantel-Haenszel: $M^2(1) = 201.1$, $p < 0.001$.

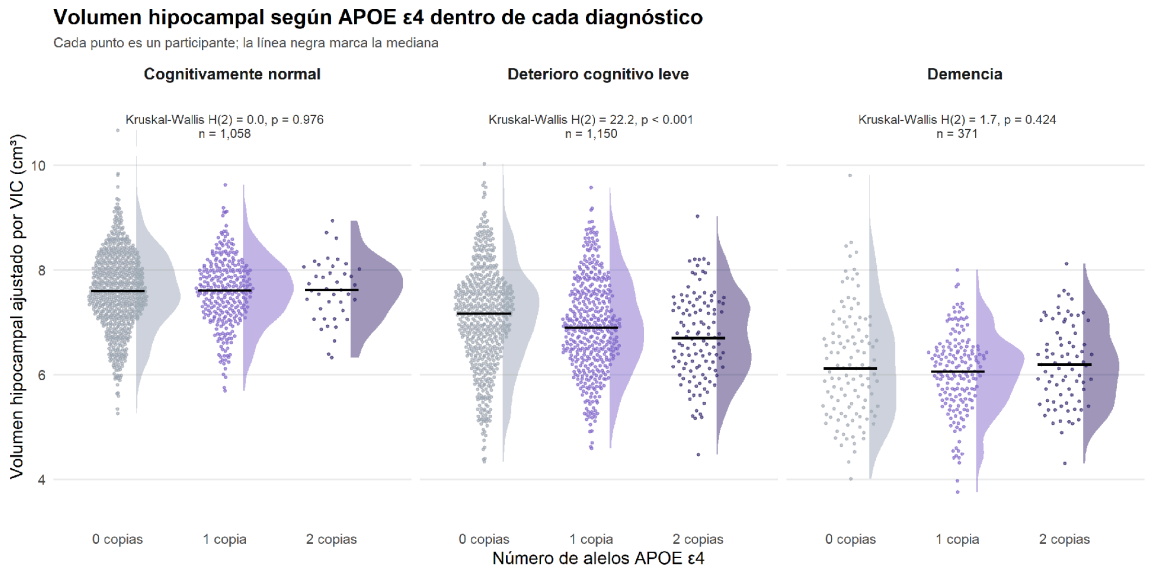


Figura 3. Volumen hipocampal total ajustado por volumen intracraneal (VIC) según alelos APOE ε4, dentro de cada diagnóstico (n = 2,579 con resonancia a ±180 días del enrolamiento). Cada punto es un participante, la curva es su densidad y la línea negra la mediana. Se usó Kruskal-Wallis porque se compara una variable numérica entre tres grupos independientes de tamaños muy desiguales, y para aplicar la misma prueba en los tres paneles; la normalidad se rechazó en CN (Shapiro-Wilk p = 0.024) y fue limítrofe en demencia (p = 0.057). CN: H(2) = 0.0, p = 0.976. MCI: H(2) = 22.2, p < 0.001. Demencia: H(2) = 1.7, p = 0.424. El efecto de ε4 sobre el hipocampo aparece en MCI, como en Hostage et al. 2013. Estratificar por diagnóstico es solo descriptivo; la mediación se evalúa con los modelos de la sección 5.

Código R. El script completo está en `Proyecto/figuras_proyecto.R`, probado en R 4.6.1. Genera `Figura1_CDRSB_APOE4.png`, `Figura2_APOE4_diagnostico.png` y `Figura3_hipocampo_APOE4.png`. Solo hay que cambiar la variable `ruta` a la carpeta `data` del paquete. El análisis completo, con modelos y post-regresión, está en `Proyecto_APOE4_ADNI.qmd`.

```
# ============================================================
# Proyecto Bioestadistica - APOE4 y diagnostico cognitivo (ADNI)
# Figuras 1, 2 y 3 (sin boxplots: cada punto es un participante)
# ============================================================

# 0. Paquetes ------------------------------------------------
paquetes <- c("dplyr", "ggplot2", "ggdist", "ggbeeswarm", "scales")
nuevos <- paquetes[!paquetes %in% rownames(installed.packages())]
if (length(nuevos) > 0) install.packages(nuevos)
library(dplyr)
library(ggplot2)
library(ggdist)
library(ggbeeswarm)
library(scales)

# 1. Cargar las tablas de ADNIMERGE2 -------------------------
# Cambia esta ruta a la carpeta "data" del paquete descomprimido
ruta <- "C:/Users/DOMINIC/Downloads/Chat Cursos
UTEC/Bioestadistica/Proyecto/ADNIMERGE2/ADNIMERGE2/data"
```

```
load(file.path(ruta, "ADSL.rda"))
load(file.path(ruta, "ADSP_PHC_T1_FS.rda"))

# 2. Base analitica ----------------------------------------
# ADSL guarda el RID en SUBJID (texto): lo pasamos a numero para unir
adsl <- as.data.frame(ADSL) %>%
  filter(ENRLFL == "Y") %>%
  mutate(RID = as.integer(SUBJID))

datos <- adsl %>%
  mutate(
    apoe4 = lengths(regmatches(as.character(APOE), gregexpr("4",
as.character(APOE)))),
    apoe4 = factor(apoe4, levels = 0:2,
                   labels = c("0 copias", "1 copia", "2 copias")),
    dx = factor(DX, levels = c("CN", "MCI", "DEM"),
                labels = c("Cognitivamente normal", "Deterioro cognitivo leve",
"Demencia")),
    raza = case_when(RACE == "White" ~ "Blanca",
                     RACE == "Black or African American" ~ "Negra",
                     is.na(RACE) ~ NA_character_,
                     TRUE ~ "Otra")
  ) %>%
  filter(!is.na(dx), !is.na(APOE), !is.na(AGE), !is.na(SEX),
         !is.na(EDUC), !is.na(raza))
nrow(datos)  # 2861

# Volumen hipocampal: resonancia mas cercana al enrolamiento (max 180 dias)
hipo <- as.data.frame(ADSP_PHC_T1_FS) %>%
  transmute(RID,
            fecha_rm = as.Date(PHC_SCANDATE),
            hv  = Left_Hippocampus_combat + Right_Hippocampus_combat,
            icv = EstimatedTotalIntraCranialVol_combat) %>%
  filter(!is.na(hv)) %>%
  inner_join(datos %>% select(RID, ENRLDT), by = "RID") %>%
  mutate(dias = abs(as.numeric(fecha_rm - ENRLDT))) %>%
  group_by(RID) %>%
  slice_min(dias, n = 1, with_ties = FALSE) %>%
  ungroup() %>%
  filter(dias <= 180)

datos_hv <- datos %>%
  inner_join(hipo %>% select(RID, hv, icv), by = "RID")
# Ajuste por volumen intracraneal (metodo de residuales, pendiente en CN)
b_icv <- coef(lm(hv ~ icv, data = filter(datos_hv, DX == "CN")))[["icv"]]
datos_hv <- datos_hv %>% mutate(hv_adj = hv - b_icv * (icv - mean(icv)))
nrow(datos_hv)  # 2579

# Colores
col_dx <- c("Cognitivamente normal"    = "#4C9BE8",
            "Deterioro cognitivo leve" = "#F2A541",
            "Demencia"                 = "#C0392B")
col_apoe <- c("0 copias" = "#9AA5B1", "1 copia" = "#7B61C9", "2 copias" = "#2D1E6B")

fmt_p <- function(p) ifelse(p < 0.001, "p < 0.001", paste0("p = ", formatC(p, digits
```

```
= 3, format = "f")))

# ============================================================
# FIGURA 1. APOE4 (exposicion) vs CDR-SB (desenlace cuantitativo)
# Histograma de puntos: cada punto es un participante, ubicado en
# su puntaje CDR-SB; la altura de cada columna es el % del grupo.
# Color = diagnostico ADNI, para ver como el puntaje lo define.
# ============================================================

datos_cdr <- datos %>% filter(!is.na(CDRSB))
nrow(datos_cdr)  # 2860

# 0a. Prueba estadistica: CDR-SB no es normal (37% en cero, sesgo a la
# derecha) y son 3 grupos independientes -> Kruskal-Wallis
kw_cdr <- kruskal.test(CDRSB ~ apoe4, data = datos_cdr)

set.seed(2026)
puntos_cdr <- datos_cdr %>%
  group_by(apoe4) %>%
  mutate(n_g = n()) %>%
  group_by(apoe4, CDRSB) %>%
  arrange(dx, .by_group = TRUE) %>%                      # CN abajo, demencia arriba
  mutate(prop = n() / n_g,
         y = (row_number() - runif(n(), 0.1, 0.9)) / n() * prop,
         x = CDRSB + runif(n(), -0.19, 0.19)) %>%
  ungroup()

resumen_cdr <- datos_cdr %>%
  group_by(apoe4) %>%
  summarise(n = n(), media = mean(CDRSB), mediana = median(CDRSB)) %>%
  mutate(lab = sprintf("n = %s\nmedia = %.2f \u00b7 mediana = %.1f",
                       trimws(format(n, big.mark = ",")), media, mediana))

# Bandas de estadio del CDR-SB (O'Bryant 2008)
bandas <- data.frame(xmin = c(-0.25, 0.25, 4.25), xmax = c(0.25, 4.25, 10.5),
                     dx = names(col_dx))

fig1 <- ggplot(puntos_cdr, aes(x = x, y = y)) +
  geom_rect(data = bandas, aes(xmin = xmin, xmax = xmax, ymin = -Inf, ymax = Inf,
fill = dx),
            inherit.aes = FALSE, alpha = 0.08, show.legend = FALSE) +
  geom_point(aes(color = dx), size = 0.75, alpha = 0.8) +
  geom_vline(data = resumen_cdr, aes(xintercept = media), linetype = "dashed",
linewidth = 0.5) +
  geom_text(data = resumen_cdr, aes(x = 10.4, y = 0.43, label = lab), inherit.aes =
FALSE,
            hjust = 1, vjust = 1, size = 3.3, color = "grey20", lineheight = 0.95) +
  facet_wrap(~ apoe4, ncol = 1, strip.position = "left") +
  scale_color_manual(values = col_dx, name = "Diagn\u00f3stico ADNI") +
  scale_fill_manual(values = col_dx) +
  scale_x_continuous(breaks = 0:10, expand = expansion(mult = 0.01)) +
  scale_y_continuous(labels = percent, breaks = c(0, 0.2, 0.4)) +
  guides(color = guide_legend(override.aes = list(size = 4, alpha = 1))) +
  labs(title = "M\u00e1s alelos APOE \u03b54, m\u00e1s puntaje CDR-SB",
       subtitle = sprintf("Kruskal-Wallis H(2) = %.1f, %s \u00b7 l\u00ednea punteada
```

```
= media del grupo",
                          kw_cdr$statistic, fmt_p(kw_cdr$p.value)),
       x = "CDR suma de cajas (0 = sin deterioro, 18 = m\u00e1ximo)",
       y = "Participantes del grupo (%)") +
  theme_minimal(base_size = 12) +
  theme(legend.position = "top",
        panel.grid.minor = element_blank(),
        panel.grid.major.x = element_blank(),
        strip.placement = "outside",
        strip.text.y.left = element_text(angle = 0, face = "bold", size = 11),
        plot.title = element_text(face = "bold"),
        plot.subtitle = element_text(size = 9.5, color = "grey30"))

fig1
ggsave("Figura1_CDRSB_APOE4.png", fig1, width = 9, height = 7.5, dpi = 300, bg =
"white")

# ============================================================
# FIGURA 2. APOE4 (exposicion) vs diagnostico (desenlace)
# Dot strip al 100%: cada punto es un participante, apilado
# dentro de su grupo en orden CN -> MCI -> Demencia.
# ============================================================

# 2a. Pruebas estadisticas
tabla <- table(datos$apoe4, datos$dx)
chi <- chisq.test(tabla)            # chi-cuadrado de Pearson (3 x 3)
min(chi$expected)                   # todas las esperadas >= 5 -> chi2 valido
# Tendencia lineal (Mantel-Haenszel lineal por lineal): ambas son ordinales
r  <- cor(as.numeric(datos$apoe4), as.numeric(datos$dx))
m2 <- (nrow(datos) - 1) * r^2
p_tend <- pchisq(m2, df = 1, lower.tail = FALSE)

sub1 <- sprintf("Chi-cuadrado de Pearson: X\u00b2(%d) = %.1f, %s  |  Tendencia
lineal: M\u00b2(1) = %.1f, %s",
                chi$parameter, chi$statistic, fmt_p(chi$p.value), m2, fmt_p(p_tend))

# 2b. Coordenadas de los puntos
set.seed(2026)
puntos <- datos %>%
  arrange(apoe4, dx) %>%
  group_by(apoe4) %>%
  mutate(n_grupo = n(),
         y = (row_number() - 0.5) / n_grupo,             # posicion acumulada 0-1
         x = as.numeric(apoe4) + runif(n(), -0.32, 0.32)) %>%
  ungroup()

etiquetas <- datos %>%
  count(apoe4, dx) %>%
  group_by(apoe4) %>%
  mutate(pct = n / sum(n),
         y = cumsum(pct) - pct / 2,
         lab = paste0(round(pct * 100), "%")) %>%
  ungroup()

n_grupo <- datos %>% count(apoe4)
```

```
fig2 <- ggplot(puntos, aes(x = x, y = y, color = dx)) +
  geom_point(size = 0.9, alpha = 0.75) +
  geom_label(data = etiquetas,
             aes(x = as.numeric(apoe4) + 0.45, y = y, label = lab, fill = dx),
             color = "white", fontface = "bold", size = 3.6,
             linewidth = 0, hjust = 0, show.legend = FALSE) +
  geom_text(data = n_grupo,
            aes(x = as.numeric(apoe4), y = 1.04, label = paste0("n = ",
trimws(format(n, big.mark = ",")))),
            inherit.aes = FALSE, size = 3.4, color = "grey30") +
  scale_x_continuous(breaks = 1:3, labels = levels(datos$apoe4),
                     limits = c(0.6, 3.75)) +
  scale_y_continuous(labels = percent, breaks = seq(0, 1, 0.25),
                     expand = expansion(mult = c(0.01, 0.06))) +
  scale_color_manual(values = col_dx, name = "Diagn\u00f3stico basal") +
  scale_fill_manual(values = col_dx, guide = "none") +
  guides(color = guide_legend(override.aes = list(size = 4, alpha = 1))) +
  labs(title = "M\u00e1s alelos APOE \u03b54, m\u00e1s participantes con MCI y
demencia",
       subtitle = sub1,
       x = "N\u00famero de alelos APOE \u03b54",
       y = "Participantes dentro de cada grupo (%)") +
  theme_minimal(base_size = 12) +
  theme(legend.position = "top",
        panel.grid.major.x = element_blank(),
        panel.grid.minor = element_blank(),
        plot.title = element_text(face = "bold"),
        plot.subtitle = element_text(size = 9.5, color = "grey30"))

fig2
ggsave("Figura2_APOE4_diagnostico.png", fig2, width = 8, height = 6.5, dpi = 300, bg
= "white")

# ============================================================
# FIGURA 3. APOE4 vs volumen hipocampal (mediador) dentro de
# cada diagnostico. Raincloud: densidad + todos los puntos.
# ============================================================

# 3a. Normalidad y prueba por diagnostico
tapply(datos_hv$hv_adj, datos_hv$dx, function(v) shapiro.test(v)$p.value)
kw <- datos_hv %>%
  group_by(dx) %>%
  summarise(H  = kruskal.test(hv_adj ~ apoe4)$statistic,
            p  = kruskal.test(hv_adj ~ apoe4)$p.value,
            n  = n(), .groups = "drop") %>%
  mutate(lab = sprintf("Kruskal-Wallis H(2) = %.1f, %s\nn = %s", H, fmt_p(p),
trimws(format(n, big.mark = ","))))
kw

fig3 <- ggplot(datos_hv, aes(x = apoe4, y = hv_adj / 1000, color = apoe4, fill =
apoe4)) +
  stat_halfeye(adjust = 0.8, width = 0.55, justification = -0.35,
               .width = 0, point_colour = NA, alpha = 0.45) +
  geom_quasirandom(width = 0.28, size = 0.7, alpha = 0.55) +
```

```
  stat_summary(fun = median, geom = "crossbar", width = 0.5,
               color = "black", linewidth = 0.35) +
  geom_text(data = kw, aes(x = 2, y = 10.75, label = lab),
            inherit.aes = FALSE, size = 3, color = "grey20", lineheight = 0.95) +
  facet_wrap(~ dx, nrow = 1) +
  scale_color_manual(values = col_apoe, guide = "none") +
  scale_fill_manual(values = col_apoe, guide = "none") +
  coord_cartesian(ylim = c(3.5, 11.1)) +
  labs(title = "Volumen hipocampal seg\u00fan APOE \u03b54 dentro de cada
diagn\u00f3stico",
       subtitle = "Cada punto es un participante; la l\u00ednea negra marca la
mediana",
       x = "N\u00famero de alelos APOE \u03b54",
       y = "Volumen hipocampal ajustado por VIC (cm\u00b3)") +
  theme_minimal(base_size = 12) +
  theme(panel.grid.major.x = element_blank(),
        panel.grid.minor = element_blank(),
        strip.text = element_text(face = "bold", size = 11),
        plot.title = element_text(face = "bold"),
        plot.subtitle = element_text(size = 9.5, color = "grey30"))

fig3
ggsave("Figura3_hipocampo_APOE4.png", fig3, width = 11, height = 5.5, dpi = 300, bg =
"white")
```